

Guía Técnica de Segmentación y Detección de Bordes

Documentación matemática y mapeo de código del framework

1. Introducción al Proceso de Segmentación

El módulo de segmentación de MC-MSA v2.5 tiene como objetivo dividir un contorno continuo de melodía y energía en frases musicales discretas. Para lograr una segmentación que respete tanto la estructura formal a gran escala como los eventos articulatorios locales, el framework implementa un enfoque híbrido secuencial en 5 pasos:

Paso 1: Extracción y Stacking	Se obtienen el contorno de afinación (f0 en escala MIDI) y la energía RMS. Se estandarizan y se apilan en un vector de características.
Paso 2: Matriz de Autosemejanza (SSM)	Se calcula la similitud de coseno entre todos los pares de frames, generando la matriz $S[i, j]$ reescalada a [0, 1].
Paso 3: Novedad Estructural (SSM)	Se convoluciona un kernel de tablero de ajedrez (checkerboard) de radio $r=8$ a lo largo de la diagonal de la matriz SSM.
Paso 4: Novedad Local (Derivadas)	Se calcula la derivada de primer orden paso a paso para el tono y la energía, capturando cambios rápidos.
Paso 5: Fusión y Detección de Picos	Ambas curvas de novedad se fusionan linealmente (60% estructural, 40% local) y se extraen los máximos locales.

2. Estandarización de Características (Z-score)

Dado que la afinación MIDI (típicamente entre 40 y 90) y la energía RMS (valores continuos muy pequeños) operan en escalas y magnitudes físicas completamente distintas, es obligatorio estandarizar el espacio de características antes de calcular la SSM. Si no se hiciera, la dimensión con mayor magnitud dominaría el cálculo de distancia.

El framework aplica una normalización Z-score independiente para cada dimensión de características:

$$x'_i = \frac{x_i - \mu_i}{\sigma_i + \epsilon}$$

donde μ y σ representan la media y la desviación estándar de la característica a lo largo del track, y ϵ es una constante pequeña ($1e-6$) para evitar divisiones entre cero en caso de silencio total. Tras esto, cada vector de frame es normalizado por su norma L2, convirtiendo el producto punto subsiguiente en una medida de **similitud de coseno**.

3. Construcción de la Matriz de Autosemejanza (SSM)

La matriz $S[i, j]$ representa la autosemejanza melódica de la pieza. Para asegurar que las celdas contengan únicamente valores positivos listos para la convolución del kernel, la similitud de coseno (que oscila en $[-1, 1]$) se reescala linealmente al rango estrictamente positivo $[0, 1]$:

$$S[i, j] = \frac{(V_i \cdot V_j) + 1.0}{2.0}$$

donde V_i y V_j son los vectores de características estandarizados y L2-normalizados en los frames i y j respectivamente. Los bloques brillantes a lo largo de la diagonal principal representan segmentos internamente homogéneos, y sus esquinas indican cambios estructurales.

4. Curvas de Novedad Local y Global

La detección de fronteras se basa en la combinación de dos principios acústico-musicales:

A. Novedad Base (Local)

Captura las transiciones rápidas locales y la articulación de notas mediante la derivada de primer orden de la melodía (pitch_diff) y de la energía (energy_diff). Se normalizan por su valor máximo respectivo, se combinan linealmente (70% melodía, 30% energía) y se filtran con un filtro Gaussiano 1D:

$$N_{\text{base}}[n] = \text{GF}_{\sigma} \left(0.7 \cdot \frac{|\Delta p[n]|}{\max_m |\Delta p[m]|} + 0.3 \cdot \frac{|\Delta E[n]|}{\max_m |\Delta E[m]|} \right)$$

B. Novedad Estructural de la SSM (Global)

Captura transiciones macro-estructurales deslizando un kernel de tablero de ajedrez K de radio r=8 (17x17 celdas en total) a lo largo de la diagonal principal de la matriz S:

$$N_{\text{raw_ssm}}[n] = \sum_{i=-r}^{r-1} \sum_{j=-r}^{r-1} S[n+i, n+j] \cdot K[i+r, j+r]$$

Para ignorar decrementos de novedad (es decir, cuando volvemos a una sección similar anterior en vez de entrar a una nueva), se aplica una rectificación de media onda (semi-rectificación), se normaliza y se suaviza usando el mismo filtro Gaussiano:

$$N_{\text{ssm}}[n] = \text{GF}_{\sigma} \left(\frac{\max(N_{\text{raw_ssm}}[n], 0)}{\max_m \max(N_{\text{raw_ssm}}[m], 0)} \right)$$

5. Fusión Híbrida y Selección de Bordes

Ambas curvas se fusionan en una curva única (N_combined) dándole prioridad a la matriz estructural (60%) sobre la local (40%), y normalizando el resultado final a un rango de [0, 1]:

$$N_{\text{combined}}[n] = \frac{0.6 \cdot N_{\text{ssm}}[n] + 0.4 \cdot N_{\text{base}}[n]}{\max_m (0.6 \cdot N_{\text{ssm}}[m] + 0.4 \cdot N_{\text{base}}[m])}$$

Peak Picking: Se identifican los picos (máximos locales) de N_combined. Un pico en el frame n se considera una frontera estructural válida únicamente si cumple dos criterios:

1. **Umbral de Altura Dinámico:** $N_{\text{combined}}[n] \geq 0.2$ (el pico debe ser al menos el 20% del pico más alto del track).
2. **Separación Mínima:** Al menos 6 frames de distancia respecto a cualquier otro límite detectado (para evitar micro-segmentos).

6. Mapeo Directo en el Código Fuente

Todos estos cálculos matemáticos están implementados de manera modular dentro de la clase **MelodySegmenter** en el archivo `src/melody_analysis_v2/segmenter.py`:

Concepto Matemático	Ecuación	Método en segmenter.py	Líneas de Código
Z-score & Estandarización	Eq. 1	<code>compute_self_similarity</code>	Línea 77-80
Similitud de Coso y SSM	Eq. 2	<code>compute_self_similarity</code>	Línea 82-85
Novedad Base (Derivada)	Eq. 3	<code>compute_novelty</code>	Línea 133-142
Convolución del Checkerboard	Eq. 4	<code>compute_checkerboard_novelty</code>	Línea 97-107
Rectificación y Normalización SSM	Eq. 5	<code>compute_checkerboard_novelty</code>	Línea 109-112
Fusión y Normalización Final	Eq. 6	<code>compute_novelty</code>	Línea 152-154
Detección de Picos (Peak Picking)	Altura ≥ 0.2	<code>find_boundaries</code>	Línea 160-172